

Système de Surveillance : AIoT pour la Prédiction Environnementale

AMGAROU SALMA, HAFDAOUI HAMZA, BOUADIF ABDELKRIM, IDRISSE HAMZA

Faculté des Sciences et Techniques ,Tanger.
Département Génie Informatique.

ABSTRACT Ce projet explore le développement d'un système de surveillance de l'environnement intelligent utilisant les principes de l'AIoT (Intelligence Artificielle des Objets). Le système intègre la simulation de capteurs dans Proteus, le traitement des données et l'apprentissage automatique dans Node-RED, et la visualisation des données pour la surveillance en temps réel et la prédiction des valeurs environnementales. Proteus est utilisé pour simuler un environnement avec des capteurs de température, humidité, Vitesse de vent et de lumière. Les données simulées sont transmises à Node-RED via une communication série. Node-RED traite les données, les prétraite et les utilise pour entraîner un modèle de Machine Learning afin de prédire les valeurs futures l'état de la météo. Les valeurs simulées et les prédictions sont visualisées sur un tableau de bord pour une surveillance en temps réel. Ce projet démontre la faisabilité de l'intégration de la simulation, du traitement des données et de l'apprentissage automatique pour créer un système de surveillance de l'environnement intelligent. Il met en évidence le potentiel de l'AIoT pour développer des solutions qui peuvent non seulement surveiller l'environnement, mais aussi prédire les changements futurs, permettant une prise de décision proactive et une optimisation des processus.

INDEX TERMS AIoT, surveillance de l'environnement, Proteus, Node-RED, apprentissage automatique, prédiction, visualisation de données

I. INTRODUCTION

L'intelligence artificielle des objets (AIoT) est la combinaison des technologies d'intelligence artificielle (IA) avec l'infrastructure de l'Internet des objets (IoT) pour réaliser des opérations IoT plus efficaces, améliorer les interactions homme-machine et améliorer la gestion et l'analyse des données. L'IA peut être utilisée pour transformer les données IoT en informations utiles pour améliorer les processus de prise de décision, créant ainsi une base pour des technologies plus récentes telles que les données IoT en tant que service. D'une part, le développement rapide du machine learning (ML) a conduit à l'émergence de nombreux services intelligents. D'autre part, les capteurs plus riches et les capacités de calcul ML améliorées des infrastructures intelligentes ont donné naissance à une nouvelle catégorie d'appareils appelés appareils AIoT. Les appareils AIoT se distinguent des nœuds de capteurs IoT traditionnels en raison de leur gamme plus large de capacités de détection, de leur capacité à effectuer des calculs complexes directement sur l'appareil et de leurs capacités de connectivité supérieures. L'AIoT est

transformationnel et mutuellement bénéfique pour les deux types de technologies, car l'IA ajoute de la valeur à l'IoT grâce aux capacités d'apprentissage automatique et l'IoT ajoute de la valeur à l'IA grâce à la connectivité, à la signalisation et à l'échange de données. À mesure que les réseaux IoT se répandent dans les principales industries, la quantité de données non structurées générées par les humains et générées par les machines augmentera de plus en plus. L'AIoT peut prendre en charge des solutions d'analyse de données qui peuvent créer de la valeur à partir de ces données générées par l'IoT. Le mariage de l'intelligence artificielle (IA) et de l'Internet des objets (IoT) crée un ensemble d'outils puissants pour la surveillance environnementale. L'AIoT permet le déploiement de vastes réseaux de capteurs qui capturent des données en temps réel sur la qualité de l'air, la santé de l'eau, la composition des sols et même les mouvements de la faune. Ces données sont ensuite introduites dans des algorithmes d'IA capables d'analyser de grandes quantités d'informations, d'identifier des tendances et de prédire les changements environnementaux. Par exemple, les systèmes

AIoT peuvent surveiller en permanence la qualité de l'air, identifier les zones présentant des niveaux de pollution élevés et identifier les sources. Cela permet aux autorités de mettre en œuvre des interventions ciblées, telles que des restrictions de circulation ou des contrôles des émissions des usines. De même, dans le domaine de la gestion de l'eau, les capteurs AIoT peuvent suivre la qualité de l'eau des rivières et des lacs, détectant dès le début les événements de contamination potentiels et permettant des mesures d'atténuation rapides. L'IA peut également analyser les conditions météorologiques et les données historiques pour prédire les sécheresses ou les inondations, permettant ainsi des stratégies proactives de conservation de l'eau ou des plans d'évacuation. L'AIoT va au-delà de la simple collecte de données. En analysant les données des capteurs au fil du temps, les modèles d'IA peuvent apprendre des relations complexes entre les variables environnementales. Cela permet de créer des modèles prédictifs capables de prévoir les changements dans les conditions météorologiques, la santé des sols ou même les routes de migration des animaux. Ces prédictions nous permettent d'être plus proactifs en matière de protection de l'environnement, en permettant une allocation ciblée des ressources et des mesures préventives pour sauvegarder notre planète. Dans le domaine de la surveillance environnementale, l'IA constitue l'épine dorsale de l'intelligence. En ingérant les données collectées par une multitude de capteurs, l'IA peut passer au crible d'énormes ensembles de données, découvrant des modèles et des corrélations cachés qui pourraient échapper à l'analyse humaine. Cela permet à l'IA de prédire les changements environnementaux, tels que les fluctuations de la qualité de l'air ou les sécheresses potentielles, avec un degré de précision plus élevé. De plus, l'IA peut être utilisée pour optimiser le placement des capteurs, garantissant ainsi la capture des données les plus critiques, et même automatiser les réponses aux menaces environnementales, permettant ainsi des interventions plus rapides et plus ciblées. Essentiellement, l'IA nous permet d'aller au-delà de la simple collecte de données vers un avenir de protection environnementale proactive.

II. TRAVAIL CONNEXE

Le domaine de la surveillance environnementale a connu une croissance exponentielle ces dernières années, alimentée par les avancées technologiques et la prise de conscience croissante des défis environnementaux auxquels notre planète est confrontée. L'intégration de l'IoT et de l'IA a ouvert de nouvelles voies pour la collecte, l'analyse et l'interprétation de données environnementales, conduisant au développement de systèmes de surveillance sophistiqués et intelligents.

Surveillance de la qualité de l'air :

La qualité de l'air est un enjeu majeur de santé publique, car la pollution atmosphérique peut avoir des effets néfastes sur les systèmes respiratoire et cardiovasculaire. Les systèmes de surveillance de la qualité de l'air basés sur l'IoT utilisent des capteurs pour mesurer la concentration de polluants tels

que les particules fines (PM2.5), l'ozone (O3), le dioxyde d'azote (NO2) et le monoxyde de carbone (CO). Ces données peuvent être utilisées pour identifier les sources de pollution, évaluer les risques pour la santé et mettre en œuvre des mesures de contrôle.

- **Modèles d'apprentissage profond :** Des études ont démontré l'efficacité des réseaux neuronaux profonds pour prédire la qualité de l'air en fonction de données historiques et de facteurs météorologiques.
- **Réseaux de capteurs :** Des réseaux de capteurs à faible coût et à haute densité ont été déployés dans les zones urbaines pour fournir une surveillance spatiale fine de la qualité de l'air.

Surveillance de la qualité de l'eau :

La qualité de l'eau est essentielle pour la santé humaine, les écosystèmes aquatiques et les activités économiques. Les systèmes de surveillance de la qualité de l'eau basés sur l'IoT utilisent des capteurs pour mesurer des paramètres tels que la température, le pH, la turbidité, la conductivité et la concentration de polluants comme les nutriments, les métaux lourds et les pesticides.

- **Détection d'événements de pollution :** Des algorithmes d'apprentissage automatique ont été appliqués pour détecter les événements de pollution de l'eau en identifiant les changements anormaux dans les données des capteurs.
- **Évaluation de la santé des écosystèmes :** La surveillance de la qualité de l'eau est essentielle pour évaluer la santé des écosystèmes aquatiques et identifier les impacts des activités humaines.

Surveillance météorologique et climatique : La surveillance des conditions météorologiques et climatiques est essentielle pour la prévision météorologique, la gestion des catastrophes naturelles et l'adaptation au changement climatique. Les systèmes de surveillance météorologique basés sur l'IoT utilisent des capteurs pour mesurer la température, l'humidité, la pression atmosphérique, la vitesse du vent, les précipitations et le rayonnement solaire.

- **Prévision météorologique :** Les données des capteurs météorologiques sont utilisées dans les modèles de prévision numérique du temps pour améliorer la précision des prévisions.
- **Gestion des catastrophes naturelles :** La surveillance des conditions météorologiques en temps réel est essentielle pour la détection précoce et la gestion des événements météorologiques extrêmes tels que les ouragans, les inondations et les sécheresses.

Surveillance de la biodiversité :

La biodiversité est essentielle pour le fonctionnement sain des écosystèmes et le maintien des services écosystémiques. Ces systèmes basés sur l'IoT utilisent des capteurs pour détecter et identifier les espèces, ainsi que des capteurs environnementaux pour surveiller les habitats.

III. Méthodologie

La méthodologie adoptée suit un flux de travail clair, commençant par l'acquisition des valeurs d'entrée, puis passant par des étapes de validation, d'authentification, de prédiction et enfin d'affichage des résultats. Tout d'abord, les valeurs d'entrée sont obtenues de l'utilisateur via une interface Node-RED. Ces valeurs sont ensuite validées pour s'assurer de leur cohérence et de leur exactitude. Si les données sont valides, Node-RED obtient un jeton d'accès pour utiliser un service d'apprentissage automatique (Machine Learning - ML) externe. Les valeurs d'entrée sont ensuite transmises au modèle ML entraîné pour effectuer la prédiction. Le résultat de la prédiction est renvoyé à Node-RED, puis affiché à l'utilisateur. En cas d'erreur lors de la validation des données, un message d'erreur est généré et affiché à l'utilisateur.

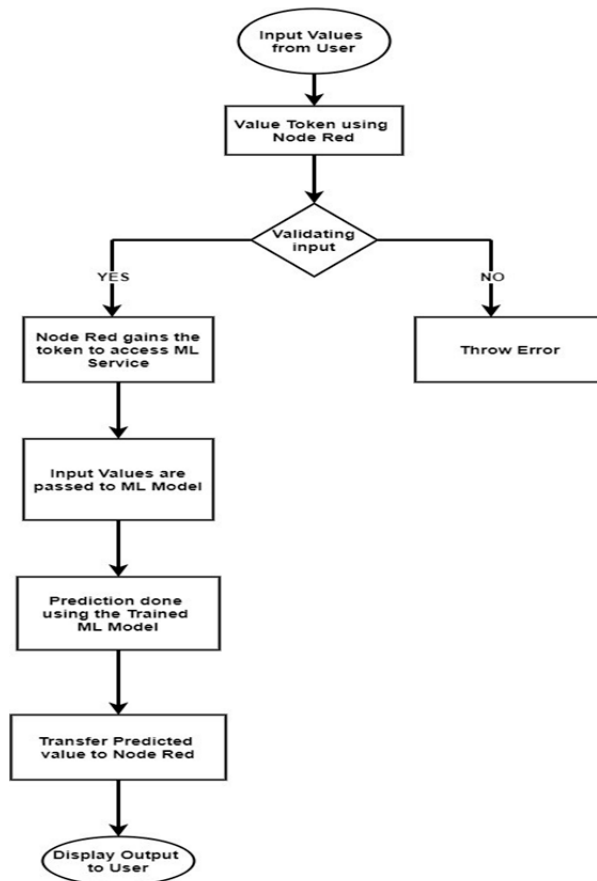


FIGURE 1. Architecture du projet

Le système proposé est composé de trois éléments principaux :

A. Simulation avec Proteus :

La simulation Proteus joue un rôle crucial dans le développement du système AIoT en fournissant un environnement virtuel pour la conception, le test et la validation du circuit et des algorithmes. Proteus permet de simuler un microcontrôleur Arduino Uno, un capteur de température et d'humidité

DHT11, un capteur de luminosité LDR et un capteur de vitesse de vent ANEMOMETR. Le générateur de signaux intégré de Proteus est utilisé pour générer des données réalistes simulant les fluctuations de température, d'humidité et de vitesse de vent, imitant ainsi le comportement des capteurs physiques dans un environnement réel. Ces données simulées sont ensuite transmises à Node-RED via une connexion série virtuelle, reproduisant le flux de données qui se produirait avec un système physique. Cette approche permet de tester et d'affiner les algorithmes de traitement des données et de prédiction dans Node-RED sans avoir besoin de matériel physique, ce qui accélère le développement et réduit les coûts. La simulation Proteus permet également d'identifier les problèmes potentiels et d'optimiser les performances du système avant son déploiement dans un environnement réel.

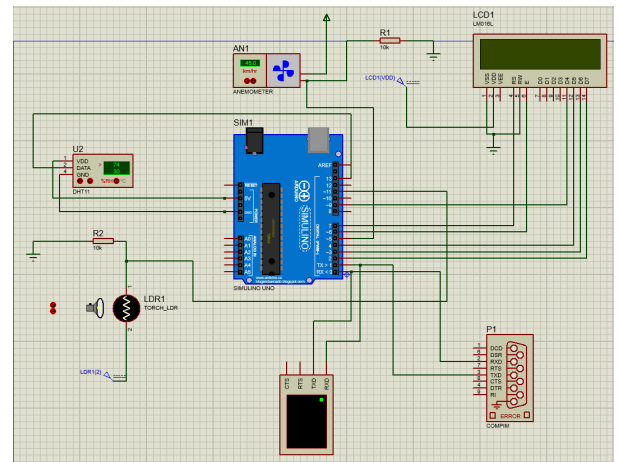


FIGURE 2. Simulation avec Proteus

1) Conception du circuit :

- Un circuit est créé dans Proteus utilisant un microcontrôleur Arduino Uno virtuel, un capteur de température et d'humidité DHT11, un capteur de vitesse de vent et un capteur de lumière.
- Un Virtual Terminal est ajouté pour simuler la communication série avec Node-RED.

2) Génération de données de capteur :

- Le générateur de signaux de Proteus est utilisé pour créer des signaux sinusoïdaux ou d'autres formes d'ondes réalistes pour simuler les fluctuations de température et d'humidité.
- Les paramètres du générateur de signaux, tels que l'amplitude, la fréquence et le décalage, sont ajustés pour obtenir des valeurs de capteur plausibles.

3) Communication série :

- Le Virtual Terminal est configuré pour envoyer les valeurs de température et d'humidité simulées au format texte via le port série virtuel.
- Le format des données peut être défini pour correspondre aux exigences de Node-RED, par exemple, des valeurs séparées par des virgules ou des espaces.

B. Traitement des données et apprentissage automatique avec Node-RED

la première partie c'est l'acquisition des données où un noeud "serial in" est utilisé pour lire les données provenant du port série virtuel créé par Proteus. Les paramètres du noeud sont configurés pour correspondre à la vitesse de transmission et au format des données provenant de Proteus. Des noeuds de fonction sont utilisés pour extraire les valeurs de température et d'humidité des données série reçues. Les valeurs analogiques sont converties en valeurs réelles de température et d'humidité en utilisant les formules de conversion spécifiques aux capteurs simulés. Les données peuvent être filtrées ou lissées pour supprimer le bruit ou les valeurs aberrantes.

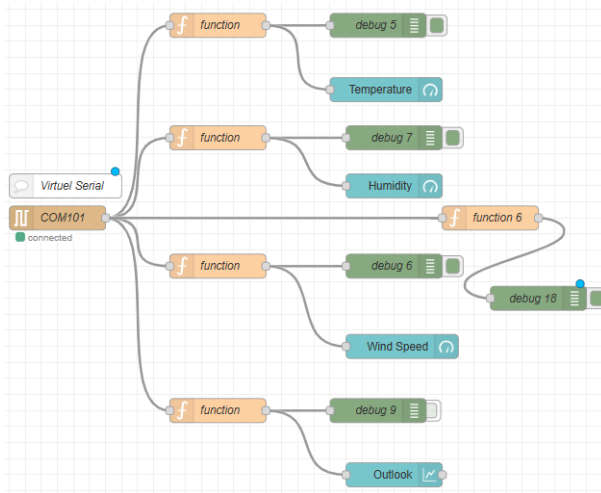


FIGURE 3. Traitement des Données

C. Entraînement du modèle d'apprentissage automatique

1) BigML :

BigML fournit une sélection d'algorithmes de Machine Learning robustes qui ont fait leurs preuves pour résoudre des problèmes du monde réel en appliquant un cadre unique et standardisé à l'ensemble de votre entreprise. Évitez les dépendances sur de nombreuses bibliothèques disparates qui augmentent la complexité, les coûts de maintenance et la dette technique dans vos projets. BigML facilite des applications prédictives illimitées dans les secteurs de l'aérospatiale, de l'automobile, de l'énergie, du divertissement, des services financiers, de l'alimentation, des soins de santé, de l'IdO, de la pharmacie, des transports, des télécommunications, etc.

Le flux Node-RED que nous avons implémenté un processus d'entraînement et d'évaluation de plusieurs modèles de Machine Learning en utilisant la plateforme BigML où :

- 1) Source : Le noeud "Source" est probablement utilisé pour charger les données d'entraînement. Il peut s'agir d'un fichier CSV, d'une base de données ou d'une autre source de données. Il est possible que trois instances du noeud "Source" soient utilisées pour charger trois

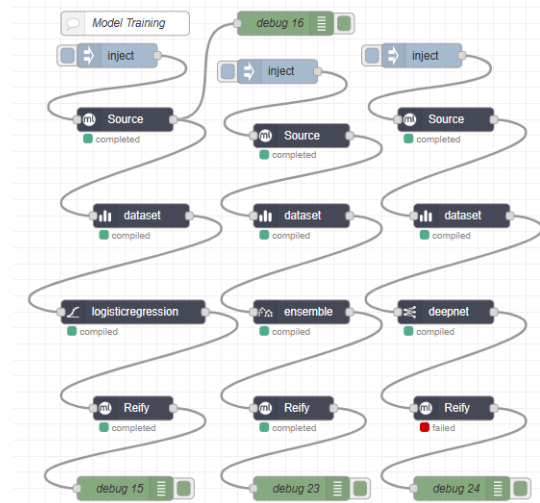


FIGURE 4. Entraînement des Modèles

ensembles de données différents, ou pour charger le même ensemble de données avec des configurations différentes.

- 2) Dataset : Le noeud "dataset" de BigML crée un ensemble de données sur la plateforme BigML à partir des données chargées par le noeud "Source". Cela implique le téléchargement des données "Outlook" vers BigML, l'analyse de la structure des données et la création d'un ensemble de données structuré pour l'entraînement des modèles.

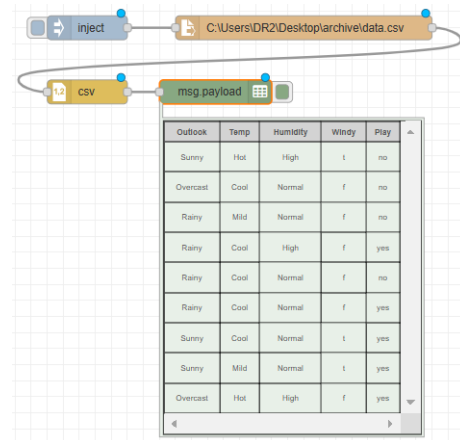


FIGURE 5. Tab

- 3) Modèles (logisticregression, ensemble, deepnet) : Trois types de modèles de Machine Learning sont entraînés en parallèle :

- logisticregression : Un modèle de régression logistique, utilisé pour la classification binaire.
- Ensemble : Un modèle d'ensemble, qui combine plusieurs modèles pour améliorer la précision et la robustesse.

- Deepnet : Un réseau neuronal profond, capable d'apprendre des représentations complexes des données. Chaque noeud de modèle utilise l'ensemble de données créé par le noeud "dataset" pour entraîner le modèle correspondant sur la plateforme BigML.

4) Reify : Le noeud "Reify" de BigML est utilisé pour matérialiser le modèle entraîné. Cela signifie que le modèle est converti en un format qui peut être utilisé pour effectuer des prédictions.

D. Test des Modèles

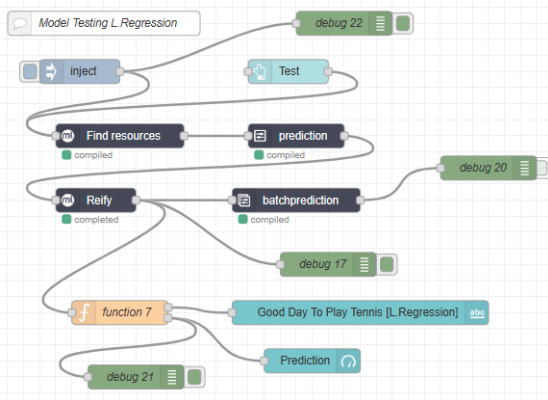


FIGURE 6. Test des Modèles

Le flux Node-RED présenté illustre le processus de test et d'utilisation d'un modèle de régression logistique ("L.Reggression") préalablement entraîné sur la plateforme BigML. Le processus commence par l'injection d'un déclencheur, qui peut être un message vide ou contenant des données de test. Ensuite, le noeud "Find resources" de BigML est utilisé pour rechercher et récupérer le modèle de régression logistique spécifique à partir de la plateforme BigML. Le noeud "Reify" matérialise ensuite ce modèle, le rendant opérationnel pour les prédictions. Deux options s'offrent alors pour la phase de prédiction : "prediction" pour des prédictions individuelles sur une seule instance de données, ou "batchprediction" pour traiter un ensemble de données complet et obtenir des prédictions pour chaque instance. Le choix entre ces deux options dépend de la nature et de la quantité de données à traiter. Un noeud de fonction personnalisé, "function 7", intervient ensuite pour manipuler les résultats de la prédiction. Son rôle exact est inconnu sans accès au code, mais il pourrait s'agir de traitement des données, de formatage ou de préparation pour la visualisation. Enfin, le noeud de sortie, nommé "Good Day To Play Tennis [L.Reggression] abc", affiche les résultats de la prédiction, suggérant que le modèle est utilisé pour prédire si les conditions sont favorables pour jouer au tennis, avec un étiquetage spécifique "abc". Des noeuds de débogage sont également présents tout au long du flux pour permettre l'inspection des données de test, des prédictions du modèle et des résultats de la fonction personnalisée. Cela facilite le

suivi du processus et l'identification de potentiels problèmes. Ce flux, bien que simple, démontre l'efficacité de BigML et Node-RED pour la création d'applications de Machine Learning. Il est possible d'enrichir ce flux en ajoutant des fonctionnalités telles que la gestion des erreurs, l'évaluation des performances du modèle, la comparaison avec d'autres modèles, et l'intégration avec d'autres systèmes pour une utilisation plus large des prédictions.

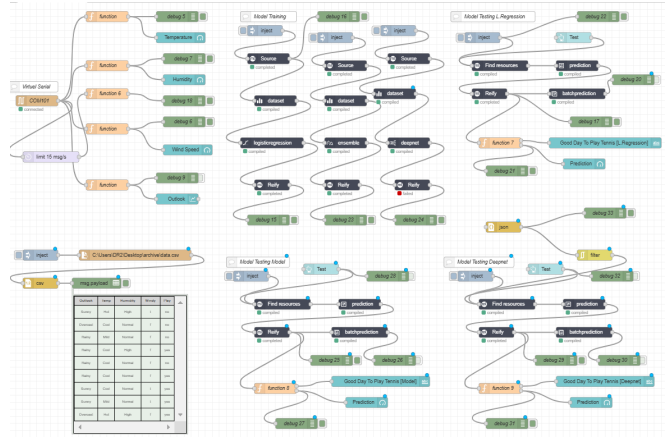


FIGURE 7. Flux Finale

E. Table de Bord

Dans ce tableau de bord interactif on a utiliser les modèles d'apprentissage automatique créer pour prédire si les conditions sont favorables à la pratique du tennis. Il présente les prédictions pour les trois modèles différents, ainsi que les données météorologiques clés telles que la température, l'humidité, la vitesse du vent et les perspectives générales. Chaque modèle fournit une prédiction binaire ("yes" ou "no") et une probabilité associée, permettant aux utilisateurs de comparer les performances des modèles et de prendre une décision éclairée quant à la possibilité de jouer au tennis. Le tableau de bord offre également la possibilité de naviguer entre différents ensembles de données ou de modèles et de déclencher de nouvelles prédictions.




FIGURE 8. Test des Modèles

IV. Discussion

L'article explore le développement d'un système intelligent de surveillance environnementale utilisant l'AIoT pour prédire les conditions météorologiques et leur impact sur la pratique du tennis. Le système repose sur la simulation de capteurs dans Proteus, le traitement des données et l'apprentissage automatique dans Node-RED, et la visualisation des résultats sur un tableau de bord. Proteus simule un environnement avec des capteurs de température, d'humidité, de vitesse du vent et de lumière, générant des données réalistes pour entraîner et tester les modèles de Machine Learning. Node-RED traite ces données, les prétraite et utilise la plateforme BigML pour entraîner trois types de modèles : régression logistique, ensembles et réseaux de neurones profonds. Ces modèles sont ensuite comparés pour déterminer lequel prédit le mieux les conditions de jeu de tennis. Un tableau de bord interactif affiche les prédictions de chaque modèle, ainsi que les données météorologiques clés, permettant aux utilisateurs de prendre des décisions éclairées. L'article met en avant l'efficacité de l'AIoT pour la surveillance et la prédiction environnementales, mais nécessite des détails supplémentaires sur l'évaluation des modèles, les défis rencontrés et les travaux futurs. Une analyse plus approfondie des métriques de performance, des erreurs de modélisation, des limitations de l'approche et des possibilités d'amélioration permettrait de renforcer la pertinence et l'impact de l'article.

Limites et Perspectives d'Avenir :

Plusieurs pistes d'amélioration peuvent être explorées pour renforcer l'efficacité du système :

- **Enrichissement du Jeu de Données :** L'utilisation de données réelles provenant de capteurs déployés dans l'environnement permettrait aux modèles d'apprendre des représentations plus précises et de mieux généraliser aux conditions réelles. L'intégration de sources de données supplémentaires, telles que les prévisions météorologiques, pourrait également améliorer les capacités prédictives.
- **Optimisation des Modèles :** Des techniques d'optimisation des hyperparamètres et l'exploration d'autres algorithmes d'apprentissage automatique pourraient mener à des modèles plus performants et généralisables.
- **Extension des Fonctionnalités :** L'ajout de capteurs pour mesurer d'autres paramètres environnementaux, tels que la qualité de l'air ou de l'eau, élargirait le champ d'application du système. Déploiement et Validation en Conditions Réelles : Tester le système dans un environnement réel permettrait de valider ses performances et d'identifier les défis potentiels liés à la mise en œuvre.

V. Conclusion

Ce projet démontre de manière convaincante le potentiel de l'AIoT pour créer un système de surveillance environnementale intelligent et prédictif. L'intégration réussie de la

simulation, du traitement des données et de l'apprentissage automatique ouvre la voie à une gestion plus proactive et efficace de notre environnement. Les résultats obtenus, malgré les limitations inhérentes au jeu de données utilisé, soulignent la capacité du système à analyser les conditions environnementales et à prédire les tendances futures. L'optimisation continue des modèles d'apprentissage automatique et l'intégration de données réelles provenant de capteurs physiques permettront d'accroître la précision et la fiabilité des prédictions. La prochaine étape cruciale de ce projet consiste à transformer cette architecture prometteuse en une solution concrète et opérationnelle. L'intégration de capteurs physiques pour collecter des données environnementales en temps réel permettra d'affiner les modèles et d'améliorer la pertinence des prédictions. Cette transition vers un système de surveillance plus précis et fiable contribuera à une meilleure compréhension de notre environnement et facilitera la prise de décisions éclairées pour sa protection. En conclusion, ce projet représente un pas important vers un avenir plus durable, où l'AIoT joue un rôle central dans la surveillance et la prédiction des changements environnementaux. La poursuite du développement et du déploiement de telles solutions innovantes contribuera à relever les défis environnementaux mondiaux et à garantir un avenir plus sain et plus résilient pour les générations à venir.

Références

- [1] ADLI, Hasyiya Karimah, REMLI, Muhammad Akmal, WAN SALIHIN WONG, Khairul Nizar Syazwan, et al. Recent advancements and challenges of AIoT application in smart agriculture : a review. *Sensors*, 2023, vol. 23, no 7, p. 3752.
- [2] FERENCZ, Katalin et DOMOKOS, József. Using Node-RED platform in an industrial environment. XXXV. Jubileumi Kandó Konferencia, Budapest, 2019, p. 52-63.
- [3] WANG, Meng, TAI, Caiwang, ZHANG, Qiaofeng, et al. Application of BigML in the classification evaluation of top coal caving. *Shock and Vibration*, 2021, vol. 2021, p. 1-28.
- [4] ANGELY, Valentin et FAVELIN, Lucien. Comment anticiper le turnover des collaborateurs ?. *Management Datascience*, 2020, vol. 4, no 3.
- [5] NOZARI, Hamed, SZMELTER-JAROSZ, Agnieszka, et GHahremani-Nahr, Javid. Analysis of the challenges of artificial intelligence of things (AIoT) for the smart supply chain (case study : FMCG industries). *Sensors*, 2022, vol. 22, no 8, p. 2931.
- [6] SUN, Zhongda, ZHU, Minglu, ZHANG, Zixuan, et al. Artificial Intelligence of Things (AIoT) enabled virtual shop applications using self-powered sensor enhanced soft robotic manipulator. *Advanced Science*, 2021, vol. 8, no 14, p. 2100230.
- [7] SEN, Ma, YUAN-YUAN, Shang, YI, Jie, et al. Research on Embedded Surveillance Platform in Severe Environment. In : 2008 Fifth IEEE International Symposium on Embedded Computing. IEEE, 2008. p. 47-52.
- [8] HOLOVATYY, Andriy. Development of IOT weather monitoring system based on Arduino and ESP8266 Wi-Fi Module. In : IOP Conference Series : Materials Science and Engineering. IOP Publishing, 2021. p. 012014.
- [9] <https://bigml.com/documentation>
- [10] <https://sriparnaiot.wordpress.com/machine-learning-with-node-redarduino/>
- [11] <https://www.labcenter.com/projectnotes/>